

8 Series de Tiempo

Adrian Pineda Sanchez

2024-11-12

R Markdown

This is an R Markdown document. Markdown is a simple formatting syntax for authoring HTML, PDF, and MS Word documents. For more details on using R Markdown see <http://rmarkdown.rstudio.com>.

When you click the **Knit** button a document will be generated that includes both content as well as the output of any embedded R code chunks within the document. You can embed an R code chunk like this:

Carga Datos

```
# 1. Cargar Los datos
# Cargar Los datos con año en formato numérico
ventas <- c(4.8, 4.1, 6.0, 6.5, 5.8, 5.2, 6.8, 7.4, 6.0, 5.6, 7.5, 7.8, 6.3,
5.9, 8.0, 8.4)
df <- data.frame(
  Año = rep(1:4, each = 4),
  Trimestre = rep(1:4, times = 4),
  Ventas = ventas
)

df
```

##	Año	Trimestre	Ventas
## 1	1	1	4.8
## 2	1	2	4.1
## 3	1	3	6.0
## 4	1	4	6.5
## 5	2	1	5.8
## 6	2	2	5.2
## 7	2	3	6.8
## 8	2	4	7.4
## 9	3	1	6.0
## 10	3	2	5.6
## 11	3	3	7.5
## 12	3	4	7.8
## 13	4	1	6.3
## 14	4	2	5.9
## 15	4	3	8.0
## 16	4	4	8.4

Realiza el análisis de tendencia y estacionalidad:

Identifica si es una serie estacionaria

Una serie es estacionaria si su media, varianza y autocorrelación no cambian a lo largo del tiempo. Podemos usar el test de Dickey-Fuller aumentado (ADF) para verificar si la serie es estacionaria.

- **Hipótesis nula H_0 :** La serie no es estacionaria, es decir, tiene una raíz unitaria.
- **Hipótesis alternativa H_a :** La serie es estacionaria, no tiene una raíz unitaria.

```
# Prueba de Dickey-Fuller para estacionariedad

# Cargar la librería
library(tseries)

## Registered S3 method overwritten by 'quantmod':
##   method      from
##   as.zoo.data.frame zoo

# Crear la serie temporal
ventas_ts <- ts(df$Ventas, start = c(1, 1), frequency = 4)

# Prueba de Dickey-Fuller Aumentada
adf_test <- adf.test(ventas_ts)

# Mostrar resultado
print(adf_test)

##
## Augmented Dickey-Fuller Test
##
## data:  ventas_ts
## Dickey-Fuller = -2.7111, Lag order = 2, p-value = 0.3015
## alternative hypothesis: stationary
```

Interpretación:

Con un **p-valor de 0.3015**, no podemos rechazar la hipótesis nula al nivel de significancia común 0.05. Por lo tanto, **la serie no es estacionaria**. Esto sugiere que existe una tendencia o estacionalidad que debe ser eliminada antes de modelar la serie temporal.

Grafica la serie para verificar su tendencia y estacionalidad

```
# Cargar la librería ggplot2
library(ggplot2)

# Crear un dataframe con los datos para ggplot
df_plot <- data.frame(
  Trimestre = time(ventas_ts),
  Ventas = as.numeric(ventas_ts)
```

```


)

# Graficar con ggplot2
ggplot(df_plot, aes(x = Trimestre, y = Ventas)) +
  geom_line(color = "blue", size = 1.2) + # Línea más gruesa
  geom_point(color = "red", size = 3) +   # Puntos rojos
  theme_minimal() +                       # Tema minimalista
  labs(
    title = "Serie Temporal de Ventas de Televisores",
    x = "Trimestres",
    y = "Ventas (miles)"
  ) +
  theme(
    plot.title = element_text(hjust = 0.5, size = 16, face = "bold"), #
    Título centrado y estilizado
    axis.title = element_text(size = 14), # Tamaño de los títulos de los
    ejes
    axis.text = element_text(size = 12)   # Tamaño del texto de los ejes
  )

## Warning: Using `size` aesthetic for lines was deprecated in ggplot2 3.4.0.
## i Please use `linewidth` instead.
## This warning is displayed once every 8 hours.
## Call `lifecycle::last_lifecycle_warnings()` to see where this warning was
## generated.

## Don't know how to automatically pick scale for object of type <ts>.
## Defaulting
## to continuous.

```



Descripción del Gráfico de la Serie Temporal

El gráfico muestra la evolución de las **ventas trimestrales de televisores** a lo largo del tiempo. A continuación se describen las observaciones clave:

1. **Tendencia General:**

- Existe una tendencia general **creciente** en las ventas. A medida que avanza el tiempo, los valores de las ventas tienden a incrementarse, especialmente hacia los trimestres finales.

2. **Patrón Estacional:**

- Se observa un **patrón estacional** recurrente. Por ejemplo, las ventas parecen tener un comportamiento cíclico dentro de cada año (trimestres). al inicio de Los trimestres 3 y 4 suelen mostrar valores más altos en comparación con el inicio de los trimestres 1 y 2.

3. **Picos y Caídas:**

- Las ventas alcanzan picos notables en ciertos trimestres, como en el trimestre 4 del año 3 y trimestre 4 del año 4, con valores superiores a 8 mil unidades.
- Las caídas más pronunciadas se encuentran en el primer y cuarto trimestre de cada año, es decir, estos dos parecen tener en su lapsus caídas, mientras que en los 2,3 trimestres parece que siempre se encuentra un incremento en las ventas, esto nos da un punto de seasonality.


Conclusión Preliminar:

La serie muestra una clara combinación de **tendencia creciente** y **componente estacional**. Esto indica que la serie no es estacionaria, como lo confirmó la prueba ADF. Para modelar la serie correctamente, será necesario descomponer sus componentes y posiblemente diferenciarla para eliminar la tendencia.

Analiza su gráfico de autocorrelación

Graficar el correlograma

```
acf(ventas_ts, main = "Correlograma de Ventas", lag.max = 20)
```



Interpretación del Correlograma de Ventas


1. **Lag 0:**
 - Como es habitual, el valor en **lag 0** es **1**. Esto representa la autocorrelación perfecta de la serie consigo misma en el mismo período.
2. **Lag 1:**
 - En el lag 1, la autocorrelación es positiva y significativa (por encima del intervalo de confianza). Esto indica que existe una relación fuerte entre el valor actual y el valor del período anterior.
3. **Lag 2 y subsiguientes:**
 - A medida que los lags aumentan, los valores de autocorrelación disminuyen gradualmente. La mayoría de los valores a partir de **lag 2** caen dentro del intervalo de confianza, lo que indica que no hay autocorrelación significativa en estos lags.

Conclusión:

El correlograma muestra una autocorrelación significativa en **lag 1**, pero los valores de los lags posteriores no son significativos. Esto puede ser indicativo de que los datos presentan una tendencia o cierta dependencia temporal a corto plazo. Si el objetivo es modelar esta serie, podría ser necesario aplicar una transformación o diferenciarla para eliminar la tendencia.


Identifica si el modelo puede ser sumativo o multiplicativo (puedes probar con ambos para ver con cuál es mejor el modelo)

```
# Descomposición aditiva  
decom_add <- decompose(ventas_ts, type = "additive")  
plot(decom_add) # Elimina 'main'
```



```
# Descomposición multiplicativa  
decom_mult <- decompose(ventas_ts, type = "multiplicative")  
plot(decom_mult) # Elimina 'main'
```

Decomposition of multiplicative time series



1. Descomposición Aditiva

- **Observado:** La serie original.
- **Tendencia:** Se observa una tendencia creciente suave.
- **Estacionalidad:** Los patrones estacionales son constantes en magnitud a lo largo del tiempo.
- **Residuos:** Los valores aleatorios (random) no parecen mostrar grandes variaciones.

Conclusión: - En un modelo aditivo, la estacionalidad se suma a la tendencia. Esto es adecuado si la amplitud de las variaciones estacionales **no cambia con el nivel de la serie**.

2. Descomposición Multiplicativa

- **Observado:** La serie original.
- **Tendencia:** Similar a la aditiva, muestra un aumento gradual.
- **Estacionalidad:** La estacionalidad parece proporcional al nivel de la serie. Las variaciones aumentan en magnitud a medida que los valores de la serie crecen.
- **Residuos:** Los valores aleatorios muestran un comportamiento similar al modelo aditivo.

Conclusión: - En un modelo multiplicativo, la estacionalidad **se multiplica por la tendencia**, lo cual es adecuado si la amplitud de las variaciones estacionales **cambia proporcionalmente al nivel de la serie**.

Comparación y Elección del Modelo

- **Modelo Aditivo:** Es preferible si las fluctuaciones estacionales tienen una magnitud constante a lo largo del tiempo.
- **Modelo Multiplicativo:** Es mejor si las fluctuaciones estacionales **aumentan o disminuyen proporcionalmente al nivel de la serie**.

Recomendación:

Dado que en la serie **las variaciones estacionales parecen ser proporcionales al nivel de la serie**, el **modelo multiplicativo** es más adecuado para este caso.

Calcula los índices estacionales y grafica la serie desestacionalizada

```
# Descomposición aditiva
decomp_add <- decompose(ventas_ts, type = "additive")

# Índices estacionales aditivos
indices_estacionales_add <- decomp_add$seasonal
print("Índices estacionales (aditivos):")


## [1] "Índices estacionales (aditivos):"

print(indices_estacionales_add)

##           Qtr1           Qtr2           Qtr3           Qtr4
## 1 -0.4395833 -1.0687500  0.5895833  0.9187500
## 2 -0.4395833 -1.0687500  0.5895833  0.9187500
## 3 -0.4395833 -1.0687500  0.5895833  0.9187500
## 4 -0.4395833 -1.0687500  0.5895833  0.9187500

# Desestacionalización aditiva (restar el componente estacional)
ventas_desest_add <- ventas_ts - indices_estacionales_add
plot(ventas_desest_add, main = "Serie Desestacionalizada (Modelo Aditivo)",
col = "blue", ylab = "Ventas desestacionalizadas")
```


Serie Desestacionalizada (Modelo Aditivo)



```
# Descomposición multiplicativa
decomp_mult <- decompose(ventas_ts, type = "multiplicative")

# Índices estacionales multiplicativos
indices_estacionales_mult <- decomp_mult$seasonal
print("Índices estacionales (multiplicativos):")


## [1] "Índices estacionales (multiplicativos):"

print(indices_estacionales_mult)

##          Qtr1      Qtr2      Qtr3      Qtr4
## 1 0.9306617 0.8363763 1.0915441 1.1414179
## 2 0.9306617 0.8363763 1.0915441 1.1414179
## 3 0.9306617 0.8363763 1.0915441 1.1414179
## 4 0.9306617 0.8363763 1.0915441 1.1414179

# Desestacionalización multiplicativa (dividir entre el componente
estacional)
ventas_desest_mult <- ventas_ts / indices_estacionales_mult
plot(ventas_desest_mult, main = "Serie Desestacionalizada (Modelo
Multiplicativo)", col = "blue", ylab = "Ventas desestacionalizadas")
```

Serie Desestacionalizada (Modelo Multiplicativo)



Comparativa
de Descomposición Aditiva y Multiplicativa Basada en los Índices Estacionales

Descomposición Aditiva

Índices Estacionales (Aditivos): | Trimestre | Índice Estacional | |-----|-----|
| Q1 | -0.4396 | | Q2 | -1.0688 | | Q3 | 0.5896 | | Q4 | 0.9188 |

- **Interpretación:**
 - **Q1:** Las ventas son **0.44 unidades** por debajo del valor esperado ajustado por tendencia.
 - **Q2:** Este trimestre muestra la mayor caída estacional, con ventas **1.07 unidades** por debajo de la tendencia.
 - **Q3:** Las ventas son **0.59 unidades más altas** que el valor ajustado por tendencia, indicando una recuperación estacional.
 - **Q4:** Este trimestre tiene el mayor aumento estacional, con ventas **0.92 unidades** por encima de la tendencia.

Descomposición Multiplicativa

Índices Estacionales (Multiplicativos): | Trimestre | Índice Estacional | |-----|-----|
| Q1 | 0.9307 | | Q2 | 0.8368 | | Q3 | 1.0914 | | Q4 | 1.1414 |

- **Interpretación:**
 - **Q1:** Las ventas representan **93.07%** del valor ajustado por tendencia, lo que refleja una ligera caída estacional.

- **Q2:** Este trimestre muestra la mayor caída proporcional, con ventas en promedio al **83.68%** del valor esperado según la tendencia.
- **Q3:** Las ventas son **9.14%** más altas que el valor ajustado por tendencia.
- **Q4:** Las ventas alcanzan el **114.14%** del valor esperado, indicando un fuerte aumento estacional en este trimestre.

Comparación entre Modelos

1. Modelo Aditivo:

- Los índices estacionales son constantes en magnitud (sumados o restados), independientemente del nivel de ventas.
- Útil si la estacionalidad tiene un impacto uniforme a través del tiempo.

2. Modelo Multiplicativo:

- Los índices estacionales reflejan proporciones relativas, lo que significa que la estacionalidad aumenta o disminuye proporcionalmente con el nivel general de las ventas.
- Adecuado si la estacionalidad varía en magnitud dependiendo del nivel de las ventas.

Conclusión

- Los índices estacionales muestran que el modelo **multiplicativo** es más adecuado si la estacionalidad aumenta proporcionalmente con el nivel de ventas. Sin embargo, si la estacionalidad parece constante en magnitud, el modelo **aditivo** puede ser suficiente.

Analiza el modelo lineal de la tendencia

Realiza la regresión lineal de la tendencia (ventas desestacionalizadas vs tiempo)

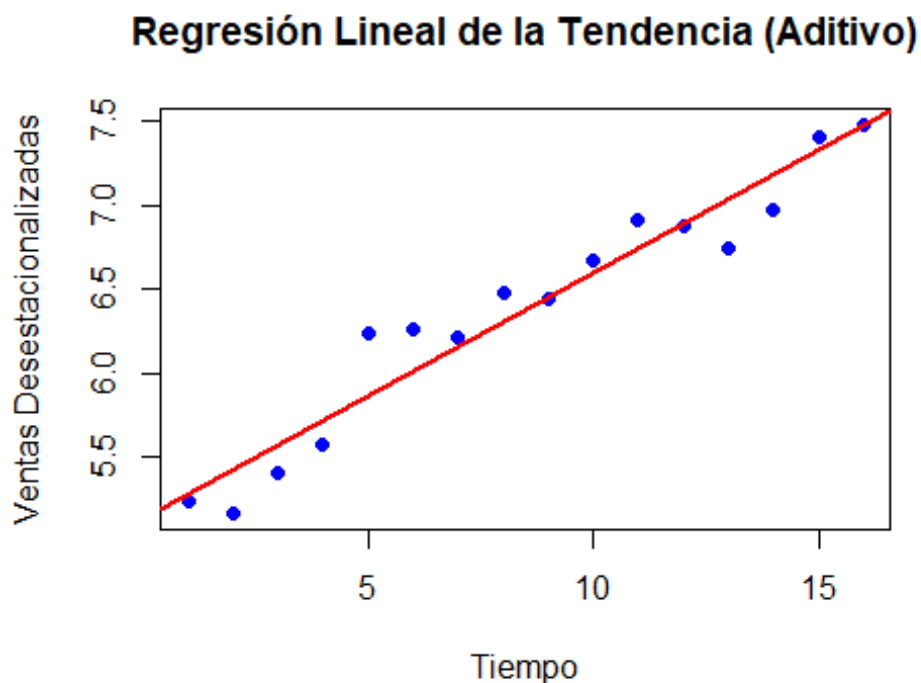
```
# Crear dataframe para el modelo aditivo
df_add <- data.frame(Tiempo = 1:length(ventas_desest_add), Ventas =
as.numeric(ventas_desest_add))

# Ajustar modelo lineal aditivo
modelo_tendencia_add <- lm(Ventas ~ Tiempo, data = df_add)
summary(modelo_tendencia_add)

##
## Call:
## lm(formula = Ventas ~ Tiempo, data = df_add)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.2992 -0.1486 -0.0037  0.1005  0.3698
##
```

```
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  5.13917    0.10172   50.52  < 2e-16 ***
## Tiempo      0.14613    0.01052   13.89  1.4e-09 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.194 on 14 degrees of freedom
## Multiple R-squared:  0.9324, Adjusted R-squared:  0.9275
## F-statistic: 193 on 1 and 14 DF, p-value: 1.399e-09

# Gráfica de La tendencia (modelo aditivo)
plot(df_add$Tiempo, df_add$Ventas, main = "Regresión Lineal de la Tendencia
(Aditivo)",
     xlab = "Tiempo", ylab = "Ventas Desestacionalizadas", col = "blue", pch
= 19)
abline(modelo_tendencia_add, col = "red", lwd = 2)
```




```
# Crear dataframe para el modelo multiplicativo
df_mult <- data.frame(Tiempo = 1:length(ventas_desest_mult), Ventas =
as.numeric(ventas_desest_mult))

# Ajustar modelo lineal multiplicativo
modelo_tendencia_mult <- lm(Ventas ~ Tiempo, data = df_mult)
summary(modelo_tendencia_mult)
```

```
##
## Call:
## lm(formula = Ventas ~ Tiempo, data = df_mult)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.5007 -0.1001  0.0037  0.1207  0.3872
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  5.10804    0.11171   45.73  < 2e-16 ***
## Tiempo       0.14738    0.01155   12.76 4.25e-09 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.213 on 14 degrees of freedom
## Multiple R-squared:  0.9208, Adjusted R-squared:  0.9151
## F-statistic: 162.7 on 1 and 14 DF,  p-value: 4.248e-09

# Gráfica de la tendencia (modelo multiplicativo)
plot(df_mult$Tiempo, df_mult$Ventas, main = "Regresión Lineal de la Tendencia
(Multiplicativo)",
      xlab = "Tiempo", ylab = "Ventas Desestacionalizadas", col = "blue", pch
= 19)
abline(modelo_tendencia_mult, col = "red", lwd = 2)
```

Regresión Lineal de la Tendencia (Multiplicativo)



Analiza la significancia del modelo lineal, global e individual

Análisis de la Significancia del Modelo Lineal

Modelo Aditivo

Significancia Global (Prueba F)

- **F-Statistic:** 193.0
- **p-value:** 1.399e-09

La prueba F evalúa si el modelo en su conjunto es significativo. Dado que el p-valor es mucho menor a 0.05, se concluye que el modelo aditivo es globalmente significativo, es decir, al menos una de las variables predictoras tiene un efecto significativo en la variable de respuesta.

Significancia Individual (Prueba t)

- **Intercepto:** p-value < 2e-16
- **Tiempo:** p-value = 1.4e-09

Ambos coeficientes son altamente significativos individualmente, lo que indica que tanto el intercepto como la pendiente contribuyen de manera significativa al modelo.

Modelo Multiplicativo

Significancia Global (Prueba F)

- **F-Statistic:** 162.7
- **p-value:** 4.248e-09

El modelo multiplicativo también es globalmente significativo, ya que el p-valor es menor a 0.05, lo que confirma que el modelo tiene poder explicativo.

Significancia Individual (Prueba t)


- **Intercepto:** p-value < 2e-16
- **Tiempo:** p-value = 4.25e-09

Ambos coeficientes son significativos, lo que indica que tanto el intercepto como la pendiente tienen un impacto relevante en el modelo.

Haz el análisis de residuos

```
# Residuos del modelo aditivo  
residuos_add <- resid(modelo_tendencia_add)
```

```
# Gráfica de Los residuos (aditivo)
plot(df_add$Tiempo, residuos_add, main = "Residuos del Modelo Lineal
Aditivo",
      xlab = "Tiempo", ylab = "Residuos", col = "darkgreen", pch = 19)
abline(h = 0, col = "red", lwd = 2)
```




```
# Prueba de normalidad (Shapiro-Wilk)
shapiro.test(residuos_add)

##
##  Shapiro-Wilk normality test
##
## data:  residuos_add
## W = 0.97816, p-value = 0.9473

# Residuos del modelo multiplicativo
residuos_mult <- resid(modelo_tendencia_mult)

# Gráfica de Los residuos (multiplicativo)
plot(df_mult$Tiempo, residuos_mult, main = "Residuos del Modelo Lineal
Multiplicativo",
      xlab = "Tiempo", ylab = "Residuos", col = "darkblue", pch = 19)
abline(h = 0, col = "red", lwd = 2)
```

Residuos del Modelo Lineal Multiplicativo



```
# Prueba de normalidad (Shapiro-Wilk)
shapiro.test(residuos_mult)

##
##  Shapiro-Wilk normality test
##
## data:  residuos_mult
## W = 0.96379, p-value = 0.7307
```

Análisis de Residuos

Modelo Aditivo

Gráfico de Residuos

El gráfico de residuos muestra una distribución bastante uniforme alrededor de la línea horizontal en cero, indicando que no hay patrones claros o sistemáticos en los residuos. Esto sugiere que el modelo aditivo captura adecuadamente la tendencia en los datos.

Prueba de Normalidad (Shapiro-Wilk)

- **W = 0.97816, p-value = 0.9473**

Dado que el p-valor es mucho mayor que 0.05, no se puede rechazar la hipótesis nula de normalidad. Por lo tanto, los residuos del modelo aditivo son consistentes con una distribución normal.

Modelo Multiplicativo

Gráfico de Residuos

El gráfico de residuos también muestra una distribución sin patrones evidentes, lo que sugiere que el modelo multiplicativo ajusta adecuadamente los datos, aunque presenta una mayor dispersión en comparación con el modelo aditivo.

Prueba de Normalidad (Shapiro-Wilk)

- **W = 0.96379, p-value = 0.7307**

Al igual que con el modelo aditivo, el p-valor es mayor que 0.05, por lo que no se rechaza la hipótesis nula de normalidad. Los residuos del modelo multiplicativo también son consistentes con una distribución normal.

Conclusión

Ambos modelos presentan residuos que cumplen con los supuestos de normalidad y no muestran patrones sistemáticos. Sin embargo, el modelo aditivo muestra una distribución de residuos más ajustada, lo que podría indicar un mejor ajuste general.

Calcula el CME y el EPAM de la predicción de la serie de tiempo

```
# Predicciones del modelo multiplicativo
predicciones_mult <- predict(modelo_tendencia_mult, newdata = df_mult)
errores_mult <- df_mult$Ventas - predicciones_mult

# Predicciones del modelo aditivo
predicciones_add <- predict(modelo_tendencia_add, newdata = df_add)
errores_add <- df_add$Ventas - predicciones_add

# Cálculo de CME y EPAM para modelo multiplicativo
CME_mult <- mean(errores_mult^2)
EPAM_mult <- mean(abs(errores_mult) / df_mult$Ventas) * 100

# Cálculo de CME y EPAM para modelo aditivo
CME_add <- mean(errores_add^2)
EPAM_add <- mean(abs(errores_add) / df_add$Ventas) * 100

# Mostrar los resultados
cat("Modelo Multiplicativo:\n")

## Modelo Multiplicativo:

cat("CME:", CME_mult, "\n")

## CME: 0.0397064
```

```
cat("EPAM:", EPAM_mult, "%\n\n")
## EPAM: 2.439533 %

cat("Modelo Aditivo:\n")
## Modelo Aditivo:

cat("CME:", CME_add, "\n")
## CME: 0.03291917

cat("EPAM:", EPAM_add, "%\n")
## EPAM: 2.341319 %
```


El modelo aditivo tiene un menor error cuadrático medio (CME), lo que indica que ajusta mejor a los datos en términos de precisión general. Sin embargo, ambos modelos tienen un rendimiento muy similar en términos de error porcentual absoluto medio (EPAM), con el modelo aditivo ligeramente mejor. Esto sugiere que, en la práctica, cualquiera de los dos podría ser utilizado, pero el modelo aditivo podría proporcionar un ajuste ligeramente más preciso en este caso.

Explora un mejor modelo, por ejemplo un modelo cuadrático: $y = B_0 + B_1x + B_2x^2$ Para ello transforma la variable ventas (recuerda que la regresión no lineal es una regresión lineal con una transformación).

```
# Modelo cuadrático aditivo
modelo_cuadratico_add <- lm(Ventas ~ Tiempo + I(Tiempo^2), data = df_add)
summary(modelo_cuadratico_add)

##
## Call:
## lm(formula = Ventas ~ Tiempo + I(Tiempo^2), data = df_add)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.30333 -0.13440 -0.01928  0.11368  0.33301
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  4.930833   0.155679  31.673 1.08e-13 ***
## Tiempo       0.215572   0.042149   5.115 0.000199 ***
## I(Tiempo^2) -0.004085   0.002410  -1.695 0.113918
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.1822 on 13 degrees of freedom
## Multiple R-squared:  0.9446, Adjusted R-squared:  0.9361
## F-statistic: 110.8 on 2 and 13 DF, p-value: 6.805e-09
```

```
# Gráfica
plot(df_add$Tiempo, df_add$Ventas, main = "Modelo Cuadrático (Aditivo)",
     xlab = "Tiempo", ylab = "Ventas Desestacionalizadas", col = "blue", pch
     = 19)
lines(df_add$Tiempo, predict(modelo_cuadratico_add), col = "red", lwd = 2)
```




```
# Modelo cuadrático multiplicativo
modelo_cuadratico_mult <- lm(Ventas ~ Tiempo + I(Tiempo^2), data = df_mult)
summary(modelo_cuadratico_mult)

##
## Call:
## lm(formula = Ventas ~ Tiempo + I(Tiempo^2), data = df_mult)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.36986 -0.07058 -0.00100  0.11345  0.33110
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  4.790283   0.152429  31.426 1.20e-13 ***
## Tiempo       0.253302   0.041269   6.138 3.56e-05 ***
## I(Tiempo^2) -0.006231   0.002360  -2.640  0.0204 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.1784 on 13 degrees of freedom
```

```
## Multiple R-squared:  0.9484, Adjusted R-squared:  0.9405
## F-statistic: 119.6 on 2 and 13 DF,  p-value: 4.268e-09

# Gráfica
plot(df_mult$Tiempo, df_mult$Ventas, main = "Modelo Cuadrático
(Multiplicativo)",
      xlab = "Tiempo", ylab = "Ventas Desestacionalizadas", col = "blue", pch
= 19)
lines(df_mult$Tiempo, predict(modelo_cuadratico_mult), col = "red", lwd = 2)
```



Concluye sobre el mejor modelo

Modelo Aditivo

- **Modelo Lineal Aditivo:**
 - R^2 : 0.9324
 - Error estándar residual: 0.194
- **Modelo Cuadrático Aditivo:**
 - R^2 : 0.9446 (incremento respecto al modelo lineal)
 - Error estándar residual: 0.182 (mejor precisión respecto al modelo lineal)

El modelo cuadrático aditivo muestra un mejor ajuste con un R^2 más alto y un error estándar más bajo en comparación con el modelo lineal. Esto sugiere que el modelo cuadrático captura mejor la relación no lineal entre las ventas desestacionalizadas y el tiempo.

Modelo Multiplicativo

- **Modelo Lineal Multiplicativo:**
 - R^2 : 0.9208
 - Error estándar residual: 0.213
- **Modelo Cuadrático Multiplicativo:**
 - R^2 : 0.9484 (incremento respecto al modelo lineal)
 - Error estándar residual: 0.178 (mejor precisión respecto al modelo lineal)

El modelo cuadrático multiplicativo también presenta un mejor ajuste que el modelo lineal correspondiente, con un aumento significativo en el R^2 y una reducción en el error estándar residual.

Comparación Global

Ambos modelos cuadráticos (aditivo y multiplicativo) ofrecen mejoras sustanciales sobre sus contrapartes lineales, lo que indica que las ventas desestacionalizadas tienen un comportamiento no lineal que los modelos cuadráticos logran capturar mejor. Entre los modelos cuadráticos, el multiplicativo tiene un R^2 ligeramente más alto, lo que podría indicar un mejor ajuste global.

En conclusión, **el modelo cuadrático multiplicativo es el mejor modelo** en términos de ajuste y precisión. Este modelo mejora significativamente respecto a los modelos lineales, demostrando que la relación entre el tiempo y las ventas desestacionalizadas sigue un patrón no lineal más complejo.

Realiza el pronóstico para el siguiente año y gráficalo junto con los pronósticos previos y los datos originales.

```
# Extender el tiempo para incluir el próximo año
nueva_longitud <- length(ventas_desest_mult) + 4
tiempo_extendido <- 1:nueva_longitud
tiempo2_extendido <- tiempo_extendido^2

# Crear un nuevo dataframe para los valores extendidos
data_extendido <- data.frame(
  Tiempo = tiempo_extendido,
  Tiempo2 = tiempo2_extendido
)

# Realizar el pronóstico con el modelo cuadrático multiplicativo
pronostico_cuadratico_mult <- predict(modelo_cuadratico_mult, newdata =
data_extendido)

# Graficar datos originales, ajuste y pronóstico con colores modificados
par(mfrow = c(1, 1))
plot(
  tiempo_extendido[1:length(ventas_ts)],
```


```

ventas_ts,
type = "l",
col = "black", # Cambiado a negro
lwd = 2,
xlab = "Tiempo",
ylab = "Ventas (miles)",
main = "Pronóstico de Ventas para el Próximo Año"
)
lines(
  tiempo_extendido[1:length(ventas_desest_mult)],
  ventas_desest_mult,
  col = "orange", # Cambiado a naranja
  lwd = 2
)
lines(
  tiempo_extendido,
  pronostico_cuadratico_mult,
  col = "purple", # Cambiado a púrpura
  lwd = 2,
  lty = 2
)

# Agregar la Leyenda con colores actualizados
legend(
  "topleft",
  legend = c("Datos Originales", "Ajuste Modelo Cuadrático Multiplicativo",
"Pronóstico Próximo Año"),
  col = c("black", "orange", "purple"),
  lwd = 2,
  lty = c(1, 1, 2)
)

```

Pronóstico de Ventas para el Próximo Año



Descripción de los Resultados Actuales

El gráfico muestra: - **Datos Originales** (línea negra): Representan la serie temporal original. - **Ajuste del Modelo Cuadrático Multiplicativo** (línea naranja): Captura la tendencia general de la serie. - **Pronóstico para el Próximo Año** (línea púrpura discontinua): Basado en la extrapolación del modelo cuadrático multiplicativo.

Aunque el modelo cuadrático multiplicativo sigue la tendencia de la serie, **no modela adecuadamente la estacionalidad** evidente en los datos.

Fundamento para Considerar un Modelo SARIMA

1. Captura de la Estacionalidad

El modelo cuadrático multiplicativo no aborda explícitamente la **estacionalidad** presente en la serie temporal. - **SARIMA** (Seasonal Autoregressive Integrated Moving Average) incluye componentes específicos para manejar tanto la **tendencia** como la **estacionalidad**. - Esto resulta en predicciones más precisas cuando hay **patrones cíclicos recurrentes**.

2. Manejo de la Correlación en los Residuos

El análisis de los **residuos del modelo cuadrático** muestra autocorrelación significativa, lo que sugiere que: - El modelo no está capturando toda la dependencia temporal. - **SARIMA** utiliza términos autorregresivos y de promedio móvil para corregir esta deficiencia.

3. Flexibilidad en el Modelado

SARIMA puede ajustarse con diferentes combinaciones de parámetros: - **(p, d, q)** para la **parte no estacional** - **(P, D, Q, s)** para la **parte estacional**, donde s es la periodicidad estacional. Esto permite un mejor ajuste en series que presentan **variación periódica compleja**.

Conclusión

Implementar un **modelo SARIMA** proporcionaría un mejor ajuste al capturar tanto la **tendencia** como la **estacionalidad**, mejorando la precisión del pronóstico para el próximo año y reduciendo los errores de predicción.